

请用蓝黑或碳素墨水书写

河海大学

硕士研究生学位论文 工作计划及开题报告书

学 号 202441029429003

研究生姓名 许文丰

学科、专业 计算机科学与技术

研 究 方 向 边缘智能

指 导 教 师 张宗帅 高级工程师
姓名、职称 毛莺池 教授

培 养 学 院 计算机与软件学院

开题报告时间 2025 年 11 月 21 日

河海大学研究生院制表

说 明

1. 学位论文计划应在导师的指导下按照培养方案要求制定。
2. 开题报告一般安排在第三学期，开题报告在负责培养的学院进行，由导师主持并邀请同行专家参加。
3. 开题报告的时间、地点须提前三天公布，欢迎师生参加旁听。
4. 论文计划书及开题报告书（空白表）由负责培养的学院于研究生入学后的第三学期初发放，第四学期初交学院汇总后存档，以备研究生院审查。
5. 本材料系永久性档案，请用蓝黑、碳素墨水或墨汁等耐久材料书写。
6. 本表可以下载打印，打印时请使用 A4 纸正反打印，不得改变表格内容及格式。签名部分必须由签名者亲笔签署。
7. 有关详细规定请查阅《河海大学研究生工作手册》。

论文计划及开题报告

计划论文题目	面向无人机群智能的云-边-端协同拆分联邦学习技术研究		
选题来源 选择打 (√)	1、国家计委、科委项目 ()； 2、国家经贸委项目 ()； 3、国家自然科学基金项目 ()； 4、国务院其它部委项目 ()；	5、主管部门(部委级)项目 ()； 6、省、市、自治区项目 ()； 7、校级项目 ()； 8、自选项目 (√)；9、其它 ()。	预 计 经 费
			约 元
预计完成日期	2027 年 5 月		
<p style="text-align: center;">主要内容（参考下列几方面）</p> <ol style="list-style-type: none"> 1. 论文的选题依据，本课题在国内外的研究动态； 2. 课题在理论或实际应用方面的意义、价值以及可能达到的水平； 3. 本人对此课题开展研究的设想，拟解决哪些重点问题； 4. 工作计划，技术路线，实验方案，预期结果； 5. 预计工作量及进度安排。 <p>计划及报告具体内容：</p> <p>一、论文的选题依据，本课题在国内外的研究动态</p> <p>1. 选题依据</p> <p>近年来，无线通信技术的快速发展极大地推动了社会的智能化进程。随着第五代(5G)网络的成熟部署，人们的关注逐渐转向下一代通信系统——第六代(6G)网络。6G 预计将实现超低时延、更高数据速率与全域连接，为智能化应用提供关键支撑。尤其是人工智能(Artificial Intelligence,AI)技术与通信网络的深度融合，被认为是 6G 网络架构演进的核心方向之一^[1]。AI 具备强大的数据分析与自学习能力，能够实现网络的自优化、自管理与智能决策，是支撑未来无线网络自治化的重要手段。</p> <p>在 5G 阶段，AI 已被应用于网络优化、流量预测及资源分配等任务，显著提升了网络性能与能效。然而，随着 6G 网络的复杂化与分布式特性增强，单一智能体或集中式 AI 已难以满足实时性与能效要求。一方面，集中式模型需要将大量数据传输至云端进行训练与决策，这不仅导致通信延迟显著增加，还难以满足任务对低时延的实时响应需求^[2]；另一方面，频繁的模式上传与全局更新会造成高能耗开销，影响系统的整体能源效率^[3]。同时，集中化的数据收集与处理过程也带来了用户隐私与数据安全风险，尤其在涉及无人机(Unmanned Aerial Vehicle,UAV)图像与环境感知数据的场景中更为突出。在此类场景中，无人机群智能系统在多任务协同过程中面临更为严峻的挑战。受限于单机算力与通信带宽，无人机在执行监测、搜救、物流等任务时，常出现计算负载与通信延</p>			

迟的不平衡问题,影响系统的实时决策与响应效率。此外,无人机受能源约束,其计算、通信与感知任务均会带来显著能耗,如何在保证任务精度与可靠性的前提下实现能量与时延的动态权衡,成为影响群体智能协同性能的关键因素。因此,亟需一种能够在云、边、端之间高效分工、兼顾能耗、延迟与隐私保护的智能协同学习机制。

拆分联邦学习(Split Federated Learning,SFL)结合了联邦学习(Federated Learning,FL)的数据隐私保护优势与拆分学习(Split Learning,SL)的计算与通信负载分担能力,为分布式 AI 训练提供了新的范式^[4],实现了高效且隐私友好的分布式模型训练。SFL 通过将模型划分为客户端和服务端两部分,实现分层协同训练。客户端利用本地数据执行前向传播,并将中间特征传输至服务器;服务器接收后完成剩余层的计算并基于损失进行反向传播,将梯度反馈给客户端以更新本地模型参数。该过程在保持数据本地化的前提下,实现了模型层面的联合优化,并可在多客户端间定期进行全局聚合,从而兼顾隐私保护、计算效率与通信开销。如图 1 所示。

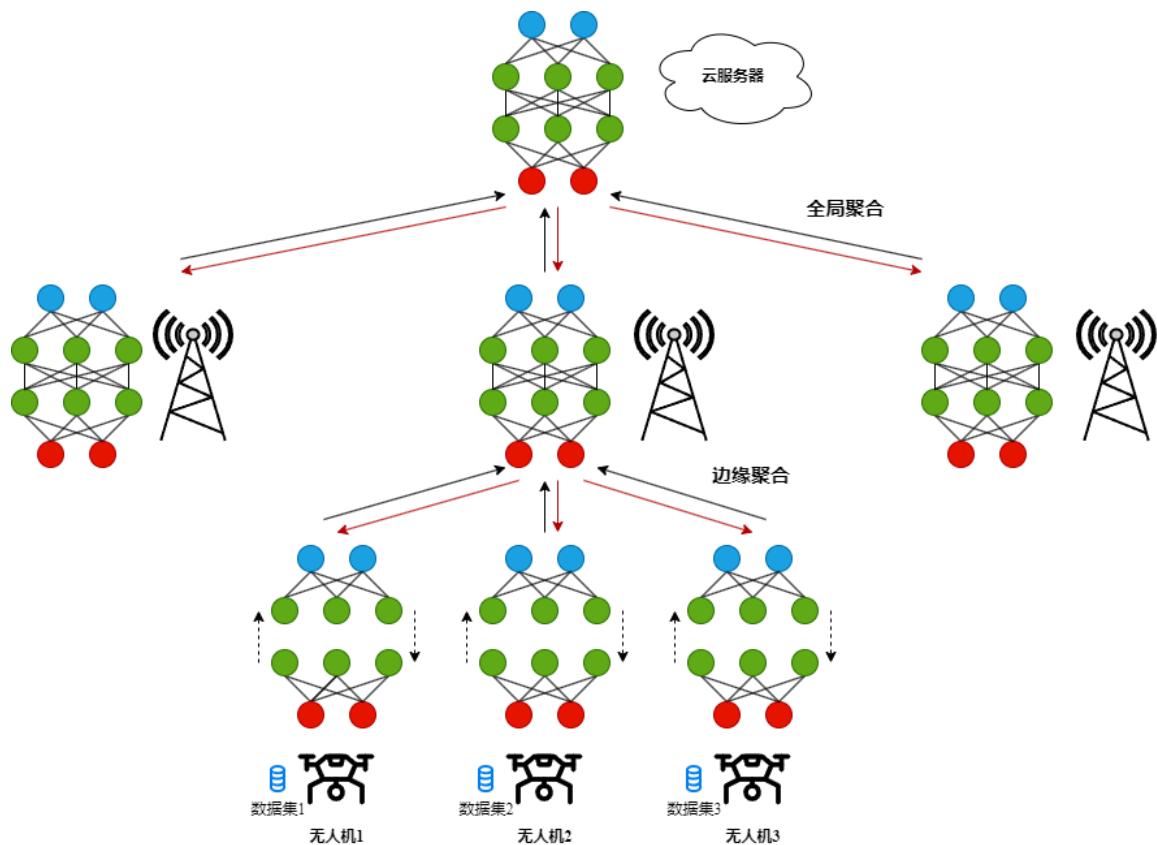


图 1 三层 SFL 架构图

然而, SFL 在多节点协同训练中虽兼顾了隐私保护与计算效率,但仍面临多方面挑战。首先,局部数据的非均衡性导致不同客户端生成的特征分布存在差异,影响全局模型的收敛稳定性与泛化性能。其次,客户端调度问题使得在大量异构设备中如何选择合

适的参与节点成为关键，若选择不当，会导致训练效率下降或模型偏差。最后，资源分配问题同样突出，SFL 需要同时协调计算、通信与能耗开销，不同客户端在带宽、算力与能量受限的情况下，如何实现高效的训练与资源分配仍是亟待解决的难题^[5]。

为应对分布式智能体在复杂无线环境下训练过程中存在的通信瓶颈与异构资源约束问题，本文进一步探索云、边、端协同的高效学习机制。为解决拆分联邦学习中局部数据非均衡、客户端调度及资源分配等问题，本论文构建了基于云-边-端三层协同架构的智能训练框架。在该架构中，云端负责全局模型聚合与策略优化，从宏观层面平衡各边缘区域间的数据分布差异；边缘层作为中间协调节点，结合局部特征统计信息进行客户端选择与任务调度，实现对异构终端的动态管理；端侧设备则根据资源状态与任务优先级自适应参与训练，从而在保证模型性能的同时，降低通信与能耗开销。通过云-边-端的分层协作，可实现对数据异质性、节点选择及资源分配的全局优化，提升拆分联邦学习的整体效率与稳定性。

2 国内外研究动态

近年来，随着人工智能和 6G 通信技术的融合加深，分布式智能系统的规模与复杂性不断提升，如何在异构环境中实现高效、可靠的智能协同成为研究热点。面对多节点、多任务的复杂训练过程，国内外学者从不同角度展开研究，以提升系统性能与资源利用率。其中，主要研究方向集中在三个方面：（1）针对局部数据非均衡导致的模型偏移与收敛不稳定问题的优化，通过改进协同训练框架与聚合机制，提高模型在非独立同分布数据下的鲁棒性与一致性；（2）通信与协作机制的设计，聚焦于用多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）在分布式环境中实现低延迟、高可靠的协同决策；（3）资源感知的能耗与时延联合优化，关注在云-边-端架构下的任务调度与资源分配，在保证性能的同时降低系统能耗与通信成本。

（1）SFL

随着分布式深度学习和边缘智能的发展，联邦学习与拆分学习逐渐成为隐私保护与分布式协同训练的两大核心范式。FL 的基本思想是各客户端在本地独立训练模型，仅上传模型参数或梯度到云端进行全局聚合，从而实现“数据不出端”的协同优化。但由于模型完整地保留在端侧，计算与存储压力较大，在资源受限的设备上难以高效训练。SL 则通过在模型中划定切分层，让客户端仅执行部分前向传播，并将中间特征上传到服务器完成后续计算，从而显著降低端侧算力与内存消耗，同时减少隐私泄露风险^[6]。

鉴于单一范式的局限，近年来，研究逐步从单一范式走向拆分-联邦混合框架^[7]，以

在通信效率、计算分担与隐私保护之间实现平衡^[8]。在此基础上，国内外学者进一步提出了多种面向非独立同分布（non-IID）数据问题的扩展方向。例如，联邦蒸馏学习通过知识蒸馏的方式仅共享模型输出或软标签，使不同客户端在知识层面进行对齐，从而缓解由数据分布差异导致的模型漂移^[9]；分层联邦学习在云-边-端的多层架构中分级聚合模型，减少非 IID 引起的全局偏差^[10]；个性化或群智联邦学习针对客户端数据分布的差异，构建个性化模型或基于相似性进行聚类，以缓解非独立同分布带来的性能退化^[11]；异步联邦学习通过异步更新机制降低慢节点对全局训练的干扰，在一定程度上缓解不同数据分布下的聚合不平衡问题^[12]；而弹性拆分学习能够根据设备算力与网络状态动态调整模型切分位置，使得数据量和特征分布差异较大的节点能够以更合理的通信与计算比例参与协同，从而稳定全局训练过程^[13]。总体而言，这些范式共同推动了分布式智能从静态集中式训练向动态、自适应、多层次协同方向演化，相关研究在提升通信效率与计算资源利用率的同时，也逐渐关注到数据非均衡带来的模型一致性与泛化性挑战，为构建在异质环境下具备稳健学习能力的分布式智能系统奠定了方法论基础。

（2）MARL

强化学习是一种通过与环境交互、基于奖惩反馈逐步学习最优策略的机器学习方法，其核心目标是最大化智能体在长期过程中获得的累积回报。传统强化学习通常依赖表格型方法或浅层函数逼近器，难以在高维连续状态空间中高效建模。为此，深度强化学习将深度神经网络引入强化学习框架，以自动提取高维感知特征，实现复杂环境下的端到端策略学习。从实现机制上看，强化学习主要可分为三类：基于价值的 RL，通过学习状态或状态-动作对的价值函数来指导策略选择，典型代表为 Q-learning；基于策略的 RL 直接优化策略函数，以实现连续动作空间的高效搜索；而参与者-批评者方法则结合了两者的优势，利用“Actor”进行策略更新、“Critic”进行价值评估，从而在稳定性与收敛性之间取得良好平衡。

MARL 是在传统 RL 基础上扩展而来，其核心思想是：每个智能体在感知局部状态并采取动作的同时，需考虑其他智能体的策略变化，从而形成复杂的博弈与协作关系。通常，MARL 可通过扩展的多智能体马尔可夫决策过程进行形式化描述，由元组 $\langle S, A, P, R \rangle$ 表示，其中 S 为环境状态空间， A 为联合动作空间， P 为状态转移概率函数， R 为奖励函数。与单智能体情形不同，多智能体的状态转移和奖励不仅取决于单个智能体的动作，还受到其他智能体行为的影响。因此，系统呈现动态博弈特性，智能体在学习最优策略时需兼顾协作与竞争关系，从而实现全局最优或均衡策略^[14]。

在多智能体系统，尤其是 UAV 集群协同控制、空域管理、任务分配与能量调度等场景中，MARL 已成为实现群体智能决策与高效协作的关键技术。传统的集中式或单智能体强化学习方法在面对动态信道环境、通信延迟及多任务耦合时，往往难以兼顾实时性与鲁棒性。而通信感知的协作式 MARL 框架通过显式建模智能体间的信息交互机制，使智能体能够在受限带宽与时变网络条件下仍实现高效的联合策略优化。Yu 等^[15]提出基于多智能体近邻策略优化的动态客户端选择机制，通过将 6G 导向车联网建模为多智能体系统并转化为去中心化部分可观测马尔可夫决策过程求解，优化车联网联邦学习中的系统开销与模型精度。Mao 等^[16]人提出基于深度强化学习的联合客户端选择与带宽分配模型，通过智能决策优化无线联邦学习中的通信资源分配与训练效率。

（3）资源感知的能耗与时延优化

随着智能计算任务逐步由集中式云平台向边缘及终端设备迁移，云-边-端协同计算架构已成为提升分布式学习效率与能效的重要研究方向。在无人机（UAV）群智能协同场景中，任务通常涉及多层级节点间的模型训练与决策交互，系统需在云端的全局决策、边缘侧的资源调度及端侧的本地计算之间实现合理分工与动态协同，以兼顾时延、能耗及通信效率等多维性能指标。

近年来，国内外研究在该领域的工作主要集中于能耗与时延的联合优化问题，并逐渐从传统的边-端双层协同架构拓展至更加复杂的云-边-端三层架构。在该多层体系中，优化目标通常涵盖以下几个方面：针对 SL 训练特性，通过调整模型切分位置与聚合频率，在通信负载与计算复杂度之间取得平衡；通过计算与通信资源分配策略协调云、边、端节点间的算力与带宽利用，以提升系统整体能效；结合无人机的任务特性与节点异构性，在保证任务执行精度的前提下实现任务调度与能量分配的协同优化。

在优化建模方面，相关问题普遍具有高维、非凸及多目标特性，通常被归类为 NP-难问题（NP-hard problem）。为应对其复杂性，学者们提出了多种求解策略：（1）将复杂的联合优化问题分解为若干可处理的子问题，并采用交替优化方法实现迭代求解；

（2）利用启发式或元启发式算法在复杂约束下高效逼近最优解；（3）采用 MARL 构建在线决策机制，实现动态环境下的自适应资源调度与跨层联合优化。Hou 等^[17]提出无人机集成感知计算通信的拆分联邦学习框架 SFLSCC，将拆分联邦学习融入 UAV 辅助联邦边缘学习以减负保隐私，构建能耗最小化优化问题并以低复杂度算法求解。Lin 等^[18]通过并行客户端模型训练与最后一层梯度聚合降低激活梯度维度及服务器计算负载，联合优化子信道分配、功率控制与切割层选择以最小化训练延迟。Shen 等^[19]通过交替

优化本地收敛阈值、迭代次数、计算资源和带宽分配，解决了非凸混合整数规划问题。Li 等^[20]人提出了一种基于 FL 和误对齐空中计算的框架，通过实时样本收集和高效模型聚合来应对数据漂移和动态信道挑战。Wang 等^[21]人设计基于信息年龄的加权联邦算法以调整局部梯度占比缓解偏移，同时通过 KKT 条件推导最优资源分配、匹配理论设计子信道分配以最小化能耗并提升设备参与率。Fan 等^[22]人将问题分解为边缘服务器间协调博弈，用 MADRL 处理分区选择、最大延迟容忍与聚合频率控制，数值方法处理资源分配来最小化训练延迟和能耗。

近年来的研究趋势进一步延伸至资源感知的 SFL 框架，将模型切分位置、客户端选择、带宽分配及计算负载动态调整统一建模为联合优化问题，以实现训练速度与系统能效的平衡。总体而言，尽管现有研究多集中于边-端协同架构，但在云-边-端三层体系下的多层资源协同与跨层优化已成为新的研究重点，对无人机智能集群、移动边缘计算及 6G 智能网络管理等场景具有重要的理论意义与应用潜力。

二、课题在理论或实际应用方面的意义、价值

本课题面向新一代智能通信网络与无人机群协同控制中的算力受限与时延敏感问题，研究基于云-边-端协同架构的拆分联邦多智能体强化学习技术，可为异构分布式系统的高效协同训练提供新的建模思路与优化方法，丰富分布式学习与智能决策的理论体系；同时，在能耗-时延联合优化、模型切分与资源分配等方面的研究，有助于推动智能计算资源管理的理论发展。所提出的框架可广泛应用于无人机集群监测、应急搜救、物流配送及车联网感知决策等场景，能够在保障实时性与能效的前提下，实现多智能体的自适应协同与任务自治，为构建智能、绿色、高效的 6G 网络与空地一体化智能系统提供重要支撑。

三、本人对此课题开展研究的设想，拟解决哪些重点问题

仅从单一层面的优化无法全面解决云-边-端协同架构下拆分联邦多智能体强化学习所面临的复杂问题。对于一个高效稳定的协同学习系统而言，数据异质性处理、智能体调度策略以及能耗-时延联合优化同等重要、相互影响。因此，需要重点考虑以下几个方面：

(1) 局部数据非均衡导致的模型偏移与收敛不稳定问题。在实际场景中，不同无人机采集的数据通常存在显著的分布差异，容易导致本地模型更新偏移、全局聚合权重分歧及灾难性遗忘等问题。为缓解数据非 IID 带来的收敛不稳定，本课题拟研究基于样本重采样/重加权或记忆回放机制的模型一致性策略。在重采样/重加权方案中，通过调

整本地训练样本的采样概率或损失权重，使少数类样本在训练中获得更高关注度，从而纠正类别不均衡导致的梯度偏差；该方法通信开销低，适用于轻量级边缘终端。在记忆/回放方案中，则通过保留部分历史样本或维护类原型特征，实现跨轮次的知识保留与表示对齐，从而减轻全局模型的遗忘效应。两种方案将结合拆分学习的特性，在边缘与云端间实现高效协同，以提升模型在异质数据环境下的鲁棒性与泛化性能。

(2) 三层架构下的无人机智能体调度问题。在云-边-端协同框架中，每个边缘服务器需在多个无人机之间选择参与训练的子集，以在有限通信与算力资源下提升系统性能。为此，拟构建基于信道质量与训练年龄的联合调度机制，通过设计优先队列动态评估各无人机的贡献度与可用性，实现边缘层的自适应智能体选择。该调度策略可通过强化学习方法进行训练，使系统在异构信道条件下仍能保持稳定收敛与高效通信。

(3) 能耗与时延的联合优化问题。在三层协同架构中，计算分配、带宽分配与模型切分位置对系统性能均具有显著影响。拟建立联合能耗-时延优化模型，将任务执行时间、传输延迟及功耗建模为通信-计算协同过程，并考虑边缘节点与无人机的异构算力与能量约束。由于该问题具有强非凸与高维特性，传统优化方法难以求解，因而拟采用 MARL 方法实现端到端优化决策。通过设计全局奖励函数和分层策略结构，使云、边、端三层节点能够在动态网络环境下自适应调整资源分配与模型切分，实现能耗与时延的最优平衡。

四、技术路线，实验方案，预期结果

1 技术路线

(1) 为了解决数据不均衡，导致的本地更新偏移、权重分歧与灾难性遗忘问题。在本地训练阶段，引入重加权策略，根据各类样本分布比例动态调整损失权重，以减轻类别不均衡导致的梯度偏差，从而提升模型在非 IID 数据下的收敛稳定性。

$$\mathcal{L}_{local} = \frac{1}{N} \sum_{i=1}^N \omega_{y_i} \ell(f_{\theta}(x_i), y_i) \quad (1)$$

其中， \mathcal{L}_{local} 为本地客户端计算的加权平均损失，用于本地参数更新。 N 本地样本总数。 x_i 为第 i 个输入样本。 y_i 为样本 x_i 的真实标签。 $f_{\theta}(\cdot)$ 为模型预测函数，参数为 θ 。 $\ell(\cdot, \cdot)$ 为单样本损失函数。所以 $\ell(f_{\theta}(x_i), y_i)$ 表示样本 i 的损失。 ω_{y_i} 表示样本 i 所属类别 y_i 的权重。

$$\omega_c = \frac{(n_{y_i})^{-\beta}}{\sum_c (n_c)^{-\beta}}, \quad \beta \in [0, 1] \quad (2)$$

其中类别权重 ω_c 定义为按类别频率的逆频率幂。 β 为平衡强度超参数，控制逆频率的幂

次。随后，在模型聚合阶段，采用动态加权聚合机制，综合考虑客户端的数据量、分布差异与历史参数变化，自适应调整聚合权重，以增强全局模型的泛化性能与训练稳定性。对第 k 个客户端聚合权重设为 ω_k ，采用下式进行归一化：

$$\widetilde{\omega}_k = n_k \cdot \exp\left(-\lambda D(P_k \parallel P_{global})\right) \cdot \exp(-\mu \|\Delta\theta_k\|_2) \quad (3)$$

$$\omega_k = \frac{\widetilde{\omega}_k}{\sum_j \widetilde{\omega}_j} \quad (4)$$

其中 n_k 是客户端 k 的样本数。 $D(\cdot \parallel \cdot)$ 表示两个分布间的差异度量。 $\Delta\theta_k = \theta_k^{(t)} - \theta_k^{(t-1)}$ 表示客户端参数的历史变化范数。 λ, μ 为超参数，控制分布差异与参数变化的惩罚强度。服务器按如下公式权重聚合：

$$\theta_{global}^{(t+1)} = \sum_k \omega_k \theta_k^{(t)} \quad (5)$$

为缓解长期训练中的知识遗忘问题，云端维护全局类原型特征并定期下发至边缘节点，使本地模型在更新过程中参考全局特征分布，从而保持模型表示空间的一致性与全局知识的持续性。

(2) 拟研究一种基于优先级队列的智能体调度算法，实现对训练参与设备的动态选择。边缘服务器将综合考虑无人机的信道质量、数据质量与训练年龄等因素，构建多维调度指标函数，并依据综合得分生成优先队列。定义无人机 i 的综合调度 S_i 公式如下：

$$S_i = \alpha \mathcal{N}(CQ_i) + \gamma \mathcal{N}(DQ_i) + \delta \mathcal{N}(Age_i) \quad (6)$$

其中， CQ_i 表示信道质量，由无人机与边缘服务器间的信噪比表示，信噪比越高，信道越好。 DQ_i 表示数据质量，综合考虑样本多样性与样本量， DQ_i 具体公式如下：

$$DQ_i = - \sum_c p_{i,c} \log(p_{i,c}) + n_i \quad (7)$$

其中， $-\sum_c p_{i,c} \log(p_{i,c})$ 为类别分布熵， n_i 为样本数量。

$$Age_i = t - t_i^{last} \quad (8)$$

Age_i 表示无人机自上次被选中以来经历的轮次数。 $\mathcal{N}(\cdot)$ 是归一化算子，将任意特征值线性映射至 $[0,1]$ 区间，确保不同量纲指标具备可比性。 α, γ, δ 为各特征权重，满足

$$\alpha + \gamma + \delta = 1 \quad (9)$$

在每轮迭代中，系统自动选择得分最高的 k 个无人机参与训练，从而实现资源利用与通信负载的动态平衡。

(3) 为解决训练过程的能耗和时延的联合优化问题，首先建立精细化的系统能耗模型与通信时延模型，系统能耗包括 UAV 模型训练能耗，传输中间特征能耗和边缘服务

器计算能耗，通信开销包括计算延迟和传输延迟。进一步，将能耗与时延指标综合构建为联合优化目标，形成能耗-时延多目标优化问题。为解决该问题，将 SFL 过程映射为联邦强化学习问题，在该框架下，UAV 被视为智能体，边缘服务器作为局部环境，云服务器负责全局聚合与策略同步。设计多维度的观测空间与动作空间，智能体 i 在第 t 轮的观测空间记为向量 o_i^t ：

$$o_i^t = [d_i, H_i, CQ_i, b_i, dist_i, Age_i, U_i, r_i^{(f)}, r_i^{(bw)}, f_i, g_m, p_t] \quad (10)$$

其中包括 UAV 的多种信息：数据量比例 d_i 、数据多样性 H_i 、信道质量 CQ_i 、电池电量 b_i 、通信距离 $dist_i$ 、更新年龄 Age_i 、综合效用值 U_i 、上轮算力 $r_i^{(f)}$ 与带宽分配份额 $r_i^{(bw)}$ 、模型结构特征 f_i 、云端宏观策略参数 g_m 及训练阶段进度 p_t 等。智能体在每轮交互中根据观测状态选择动作向量 a_i^t ：

$$a_i^t = [a_i^{(split)}, a_i^{(iter)}, a_i^{(f)}, a_i^{(bw)}] \quad (11)$$

其中动作空间包括：模型切分层索引 $a_i^{(split)}$ 、本地迭代次数 $a_i^{(iter)}$ 、算力分配比例 $a_i^{(f)}$ 和带宽分配比例 $a_i^{(bw)}$ 。该设计使智能体能够在结构层与资源层同时进行自适应决策，从而实现计算-通信-学习三要素的协同优化。

2 实验方案

步骤 1：确定数据集和训练模型。本实验拟采用 CIFAR-10、CIFAR-100 和 MNIST 三种公开数据集，模型选择 ResNet-18。

步骤 2：SFL 系统搭建与任务分配。搭建三层拓扑：云端、边缘服务器与 UAV 终端。每个 UAV 按本地数据训练其客户端侧模型并与其边缘服务器交互，边缘按配置执行周期性边缘聚合，云端周期性进行全局聚合。

步骤 3：系统能耗与时延模型实现。依照具体公式，实现每个 UAV 的计算能耗模型与通信时延模型。

步骤 4：MARL 环境准备。MARL 框架采用 MAPPO 架构。在训练阶段，所有智能体共享一个集中式价值网络，利用全局状态信息估计联合状态-动作价值；在执行阶段，智能体拥使用策略网络基于自身局部观测进行自主决策。

步骤 5：开展实验。依照改进好的训练策略、调度算法和 MARL 算法使用搭建完善的架构开展实验，重复训练流程直到收敛或达到停止标准。训练流程如图 2 所示。

步骤 6：基线方法。为验证所提多智能体强化学习优化框架的有效性，设计多种对照方法进行性能比较。对照方法包括联邦平均，拆分学习，交替优化，启发式算法和单

智能体强化学习等。

步骤 7：评价指标。实验从全局验证集准确率、收敛速度、精度提升率、总能耗和通信开销等多项指标进行评估。

步骤 8：结果报告。绘制训练轮次与全局精度、能耗及时延变化趋势，比较不同方法的收敛速度与稳定性。汇总各基线方法与所提方法在主要指标上的定量结果，展示性能提升幅度。

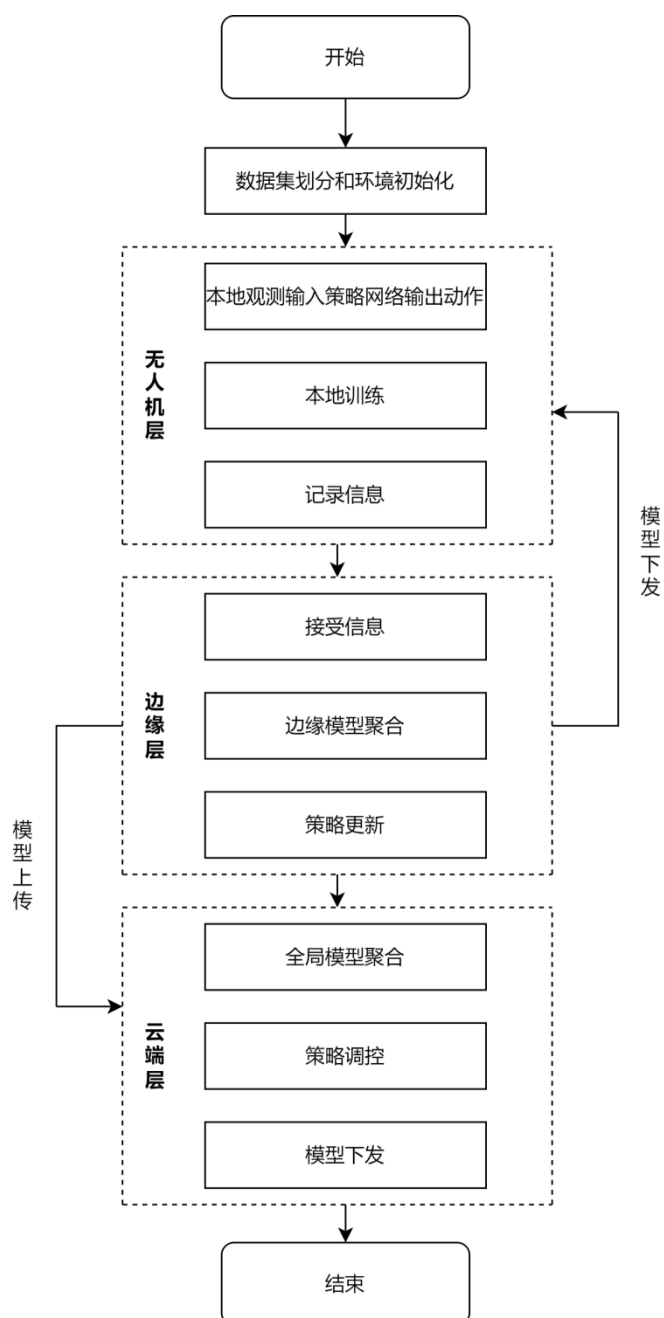


图 2 训练流程图

3 预期结果

本论文预计所提出的基于拆分联邦学习的多智能体强化学习云-边-端协同优化技术，能够在动态环境中实现无人机智能集群的自适应资源调度与高效协同学习，显著降低任务执行中的能耗与通信延迟。该方法可提升无人机群在复杂场景下的自主决策与协同感知能力，为能源受限的空中智能系统提供高效、可扩展的模型训练与任务分配机制，具有良好的工程应用潜力与现实推广价值。

五、预计工作量及进度安排

(1) 2025.09 —— 2025.12 查阅相关文献，总结对比现有算法，完成开题报告。

(2) 2026.01 —— 2026.03 广泛收集并阅读相关资料，深入研究拆分联邦学习中模型分布式训练方法。

(3) 2026.04 —— 2026.06 分析现有方法存在的问题，提出针对性解决方案措施，融合现有方法的优点，完成理论方法总结。

(4) 2026.07 —— 2026.08 搭建实验环境，完成现有算法以及改进算法的实现。

(5) 2026.09 —— 2026.11 对论文提出的算法与方案进行实验比较验证。


(6) 2026.12 —— 2027.05 撰写论文，参加答辩。

参考文献：

- [1] Cui Q, You X, Wei N, et al. Overview of AI and communication for 6G network: fundamentals, challenges, and future research opportunities[J]. Science China Information Sciences, 2025, 68(7): 171301.
- [2] You X, Huang Y, Zhang C, et al. When AI meets sustainable 6G[J]. Science China Information Sciences, 2025, 68(1): 110301.
- [3] Chen Q, Song X, Song T, et al. Vehicular Edge Computing Networks Optimization via DRL-Based Communication Resource Allocation and Load Balancing[J]. IEEE Transactions on Mobile Computing, 2025.
- [4] Cai H, Zhou Z, Huang Q. Online resource allocation for edge intelligence with colocated model retraining and inference[C]//IEEE INFOCOM 2024-IEEE Conference on Computer Communications. IEEE, 2024: 1900-1909.
- [5] Tao M, Zhou Y, Shi Y, et al. Federated edge learning for 6G: Foundations, methodologies, and applications[J]. Proceedings of the IEEE, 2024.
- [6] Le M, Huynh-The T, Do-Duy T, et al. Applications of distributed machine learning for the internet-of-things: A comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2024.
- [7] Thapa C, Arachchige P C M, Camtepe S, et al. Splitfed: When federated learning meets split learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2022, 36(8): 8485-8493.
- [8] He W, Yao H, Wang F, et al. Enhancing the efficiency of uav swarms communication in 5g networks through a hybrid split and federated learning approach[C]//2023 International Wireless Communications and Mobile Computing (IWCMC). IEEE, 2023: 1371-1376.
- [9] Bai J, Dong H, Qin A K. On the Fast Adaptation of Delayed Clients in Decentralized Federated Learning: A Centroid-Aligned Distillation Approach[J]. arXiv preprint arXiv:2508.02993, 2025.
- [10] Hamood M, Albaseer A, Abdallah M, et al. Optimized federated multitask learning in mobile edge networks: A hybrid client selection and model aggregation approach[J]. IEEE Transactions on Vehicular Technology, 2024.
- [11] Xia Z, Hu M, Yan D, et al. MultiSFL: Towards Accurate Split Federated Learning via Multi-Model Aggregation and Knowledge Replay[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(1): 914-922.
- [12] Zheng J, Liu X, Ling Z, et al. Aou-based local update and user scheduling for semi-asynchronous

- online federated learning in wireless networks[J]. IEEE Internet of Things Journal, 2024, 11(18): 29673-29688.
- [13] Hafi H, Brik B, Bagaa M, et al. Impact of neural network depth on split federated learning performance in low-resource UAV networks[C]//2024 International Wireless Communications and Mobile Computing (IWCMC). IEEE, 2024: 1290-1295.
- [14] Li Y, Jin B, Li X, et al. FedRL-Hybrid: A federated hybrid reinforcement learning approach[J]. Information Sciences, 2025, 710: 122102.
- [15] Yu T, Wang X, Hu J, et al. Multi-agent proximal policy optimization-based dynamic client selection for federated AI in 6G-oriented internet of vehicles[J]. IEEE Transactions on Vehicular Technology, 2024, 73(9): 13611-13624.
- [16] Mao W, Lu X, Jiang Y, et al. Joint client selection and bandwidth allocation of wireless federated learning by deep reinforcement learning[J]. IEEE Transactions on Services Computing, 2024, 17(1): 336-348.
- [17] Hou X, Wang J, Zhang Z, et al. Split federated learning for UAV-enabled integrated sensing, computation, and communication[J]. arXiv preprint arXiv:2504.01443, 2025.
- [18] Lin Z, Zhu G, Deng Y, et al. Efficient parallel split learning over resource-constrained wireless edge networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(10): 9224-9239.
- [19] Shen Y, Qu Y, Dong C, et al. Joint training and resource allocation optimization for federated learning in UAV swarm[J]. IEEE Internet of Things Journal, 2022, 10(3): 2272-2284.
- [20] Li Y, Liu Y. An Online Federated Learning Framework via Over-the-Air Computing for UAV Object Detection[J]. IEEE Transactions on Vehicular Technology, 2024.
- [21] Wang K, Ding Z, So D K C, et al. Exploring age-of-information weighting in federated learning under data heterogeneity[J]. IEEE Transactions on Wireless Communications, 2025.
- [22] Fan W, Chen P, Chun X, et al. MADRL-based model partitioning, aggregation control, and resource allocation for cloud-edge-device collaborative split federated learning[J]. IEEE Transactions on Mobile Computing, 2025.

导师签名:



2025 年 11 月 12 日



2025 年 11 月 12 日

(本页不够写可续页)

同行专家签名：_____、_____、_____、

_____、_____、_____

年 月 日

学院院长审核意见：

学院院长签名：_____

年 月 日